



1. Continuidad con Deliverable 1 y desviaciones declaradas

Se mantiene: la tarea (horario semanal de 10 médicos en 21 turnos, salida JSON), la entrada de Deliverable 1 (`inst_00`), el criterio de corrección (0 violaciones de HC1–HC6 según `src/verifier.py`) y el prompt directo como línea base. **Desviaciones declaradas (la evaluación queda más exigente, no más fácil):**

- **HC1:** el código de Deliverable 1 solo revisaba Noche→Mañana. Ahora el descanso se calcula con los horarios reales (06–14, 14–22, 22–06) y se exige ≥ 16 h, así que también quedan prohibidos Noche→Tarde (ya prohibido en el texto de Deliverable 1) y Tarde→Mañana.
- **La evidencia de Deliverable 1 era simulada:** `baseline_direct.py` evaluaba una salida escrita a mano (7.4 viol./intento). Con el modelo real y el mismo prompt: **0/30 válidos, 23.4 viol./horario** (rango 10–49). El modelo llena casi todas las plazas (40 de 42), pero rompe las reglas: especialidad (HC4, 39 %), bloqueos (HC6, 18 %), descanso (HC1, 15 %), horas (HC5, 11 %).
- **De 1 a 30+30 instancias:** 30 a la escala de Deliverable 1 (`inst_00` es su escenario) y 30 de *estrés* (+1–3 franjas bloqueadas por médico). Todas se certificaron factibles con CP-SAT *solo al construir el dataset*.

2. Modelo seleccionado

meta-llama/Llama-3.2-3B-Instruct, revisión 0cb88a4, 4-bit NF4 (bitsandbytes 0.50.2, transformers 5.16.1, torch 2.13+cu130), decodificación greedy, en la **RTX 5060 8 GB** declarada en Deliverable 1 (2.4 GB de VRAM). Mismo pipeline, instancias y verificador para los tres candidatos de Deliverable 1:

Modelo	Parám.	Directo	Solución	Sol. estrés
Llama-3.2-3B (elegido)	3.21B	0/30	30/30	28/30
Qwen2.5-3B (comparación)	3.09B	0/30	29/30	26/30
Phi-3.5-mini (comparación)	3.82B	0/30	30/30	27/30
Qwen2.5-1.5B ^b	1.54B	0/30	25/30	27/30
Qwen2.5-0.5B ^b	0.49B	0/30	29/30	27/30

^b Ablación de tamaño, fuera de la lista de Deliverable 1; no forma parte del sistema.

Por qué Llama-3.2-3B sobre los otros dos: las instrucciones permiten comparar los candidatos, así que corrimos los tres. Llama es el que más horarios resuelve. Frente a Qwen resuelve 3 instancias más (1 principal, 2 estrés), con solo un 4 % más de parámetros y menos sesgo de posición (33 % vs. 47 %; azar: 17 %). Frente a Phi es un 16 % más pequeño y resuelve una instancia más de estrés. Con $N = 30$ las diferencias son pequeñas (el azar también llega a 30/30 con el mismo andamiaje), así que pesó que Llama casi no cuesta tamaño frente al más pequeño. **Costo:** exige aceptar la licencia de Meta en Hugging Face (repositorio *gated*); el README explica el trámite.

3. Intervención y vínculo con el fallo de Deliverable 1

El LLM ya no escribe la semana: decide **un turno por llamada** y el código hace lo que el modelo no sabe hacer. Deliverable 1 diagnosticó tres fallos, que aquí llamamos **F1** (decisión voraz, sin retroceso), **F2** (deriva de estado y aritmética) y **F3** (alucinación de esquema e IDs). Cada uno tiene un componente que lo ataca: **F2 (deriva de estado)** → el estado lo lleva el código y llega al modelo como tabla, junto con los candidatos legales. **F3 (esquema/IDs)** → un *LogitsProcessor* con un trie de tokens solo deja emitir combinaciones válidas (dotación exacta y cuota de especialidad); el JSON lo arma el código. **F1 (voraz, sin retroceso)** → un chequeo de capacidad restante descarta opciones que dejan la semana sin salida, y un retroceso cronológico (máx. 30) deshace las elecciones que llevan a un callejón sin salida. Si se agota el presupuesto, el horario se completa relajando restricciones y se marca **no certificado**. Ningún horario inválido salió certificado.

4. Resultados contra la línea base

$N = 30$ instancias por conjunto; el mismo verificador y el mismo criterio (válido = 0 violaciones) en todas las filas. Llama-3.2-3B, decodificación greedy (determinista).

Estrategia	Válidos	Viol.	Llam.
<i>Conjunto principal</i> (<code>inst_00</code> = escenario de Deliverable 1)			
Directo (línea base)	0/30	23.4	1
Reparación con verificador	0/30	26.6	4
Paso a paso <i>sin</i> pasos 3 y 5	3/30	3.3	21
Solución (pasos 1–5)	30/30	0	21.9
<i>Conjunto de estrés</i> (+ franjas bloqueadas)			
Directo (línea base)	0/30	26.0	1
Solución (pasos 1–5)	28/30	0.20	25.2
<i>Ablación sin LLM</i> (pasos 1–5 eligiendo al azar)			
Principal / estrés	30/30 / 26/30	0 / 0.27	0

Viol. = violaciones duras medias por horario; Llam. = llamadas al LLM por horario. Tiempo por horario en la RTX 5060: directo 12.8 s, solución 11.9 s.

5. Estrategias alternativas evaluadas

- **Reparación con feedback del verificador** (la opción “CoT con verificación” del plan de Deliverable 1): no mejora, e incluso empeora (26.6 viol./horario vs. 23.4 del directo). En 80 de 90 rondas (89 %) las violaciones no cambian: el modelo reescribe casi el mismo horario aunque recibe la lista exacta de errores.
- **Paso a paso sin pasos 3 y 5:** F2 y F3 desaparecen (0 errores de HC2, HC3, HC4 o de formato), pero solo 3/30 son válidos. El 82 % de las violaciones son HC5 y el 16 % HC1: sin retroceso, el LLM pone más especialistas de los exigidos en el 24 % de los turnos con cuota, agota sus horas y el fin de semana queda sin opciones legales. Es el fallo F1 tal como lo describió Deliverable 1.
- **Eligiendo al azar** (fila “Ablación”): 30/30 y 26/30; la corrección viene sobre todo del andamiaje.

6. Caso de falla: stress_04 (conjunto de estrés)

En el conjunto principal Llama no falla (30/30); bajo estrés falla en 2 de 30. En **stress_04** la solución agota sus 30 retrocesos, completa la semana relajando reglas y marca el horario como **no certificado** (4 violaciones HC5). **Por qué falla, en cadena:**

- 1. Instancia al límite.** Los 14 turnos de día exigen un urgenciólogo, y los 3 urgenciólogos suman exactamente 14 turnos de capacidad (5+4+5). Cada turno de Urgencia tiene que caer en el lugar justo.
- 2. El modelo repite al mismo especialista.** Asigna a `DOC_04` todas las mañanas de lunes a viernes. Según CP-SAT (`diagnose.py`), la semana deja de tener solución en la tercera, el *miércoles Mañana*. A `DOC_04` y `DOC_05` les quedan 4 turnos para 9 plazas, así que `DOC_06` debe trabajar los 5 días restantes desde el miércoles en la tarde, y la regla Tarde→Mañana lo encadena a las tardes hasta el domingo, cuando está bloqueado.
- 3. El chequeo hacia adelante no lo ve.** Compara totales (9 = 9 cuadra) y no si cada médico puede tomar cada turno concreto. Ese miércoles admitió 6 opciones y solo 3 permitían terminar la semana.
- 4. El retroceso no alcanza.** El choque aparece 10 turnos después (sábado Tarde). Para volver al miércoles, el retroceso cronológico tendría que agotar ~390 000 combinaciones intermedias, y su presupuesto es de 30.

Evidencia: con el mismo andamiaje, la elección al azar reparte a los urgenciólogos y resuelve **stress_04** sin retroceder; los 5 LLMs probados fallan. La otra falla, **stress_25**, ocurre también con el azar: ahí el límite es solo del andamiaje. Qwen-3B (sesgo de 47 %) falla además en `inst_28` por el mismo mecanismo. Es F1 de Deliverable 1 reapareciendo *dentro* de la elección.

7. Límites conocidos

- El chequeo hacia adelante es condición necesaria, no suficiente, y el retroceso cronológico no llega a errores lejanos (28/30 en estrés). Reproducir exige aceptar la licencia de Meta.
- Semana aislada (sin domingo→lunes); las opciones crecen como $\binom{n}{k}k!$ (~24 000 por paso con 30 médicos y 3 por turno).

8. Reproducción

Video: `src/demo.py --random` · tabla: `src/evaluate.py --summary` · falla: `src/diagnose.py --set stress --instance stress_04`. Salidas crudas en `results/`; pasos en el README.